



西安电子科技大学
XIDIAN UNIVERSITY

基于深度网络的高质量事件序列（Event Sequence）重建

- 答辩人：

电子工程学院 张志宏

- 指导老师：

清华大学 索津莉 副教授

西安电子科技大学 李洁 教授



目录

CONTENTS

01

研究背景与研究现状

02

研究思路与解决方案

03

实验结果与对比分析

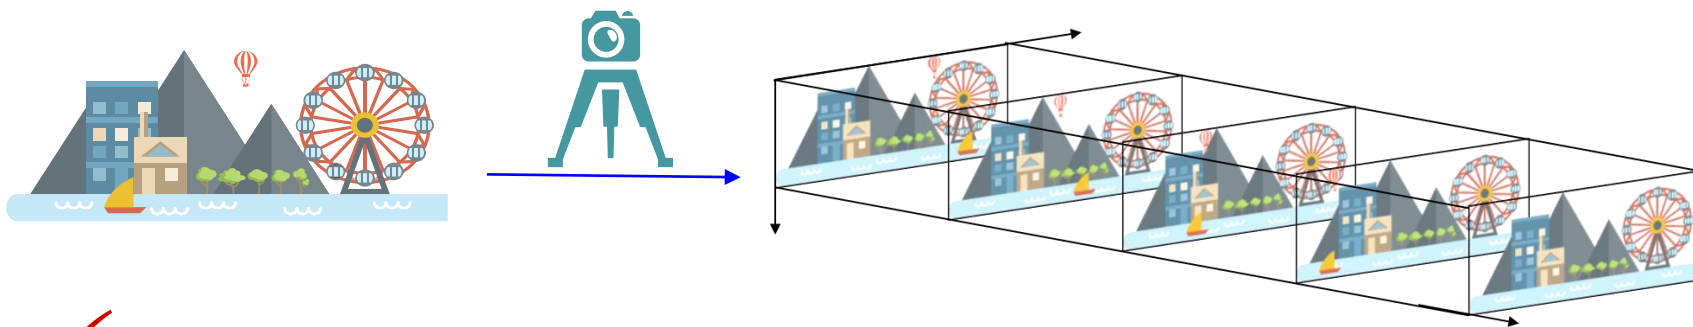
04

总结与展望



研究背景

基于帧的成像体系



- 技术成熟，应用广泛
- 空间分辨率高



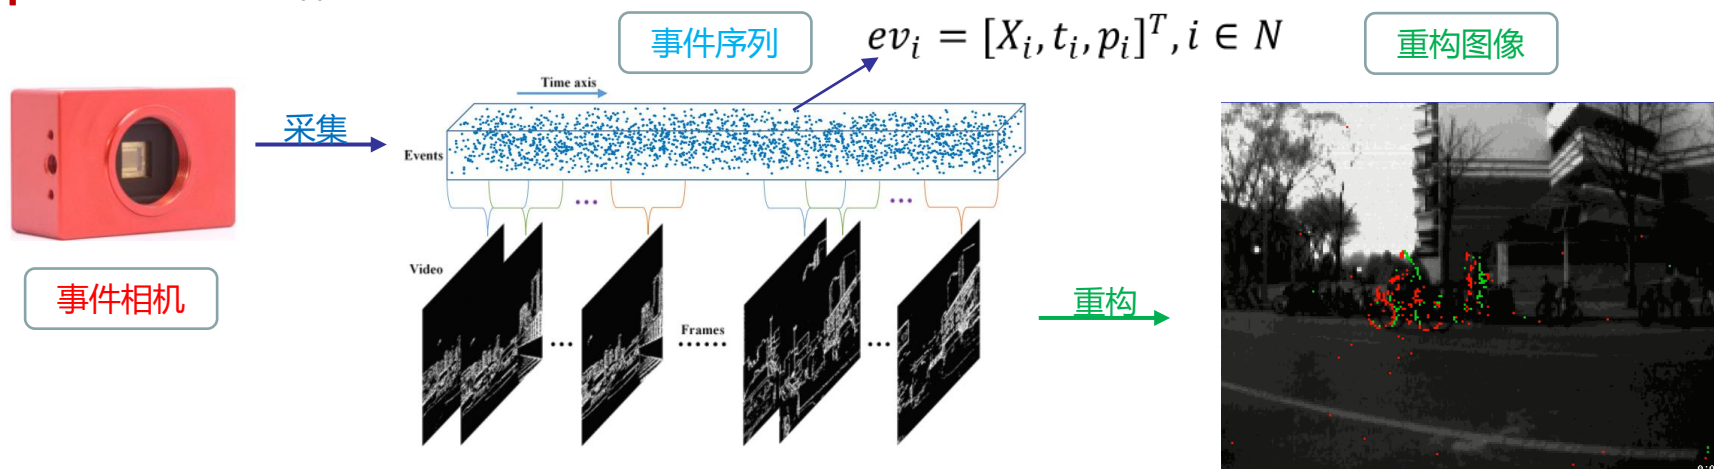
- 帧率受限，存在高速运动模糊
- 数据冗余，占用带宽较大
- 动态范围小






研究背景

基于事件成像体系



What is an Event Camera (DVS)?



standard
camera
output:

time




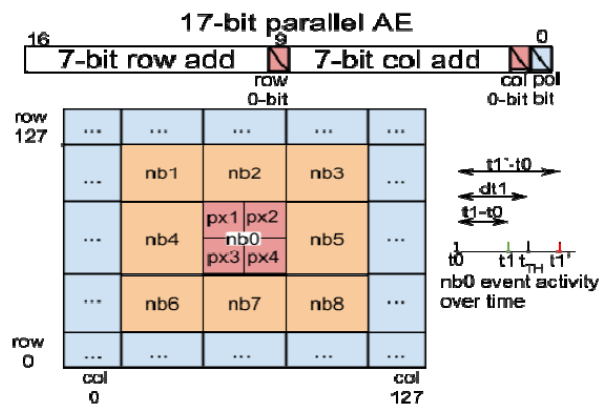
- 低延迟 —— 微秒级时间分辨率
- 低冗余、低功耗 —— 动态视觉成像
- 高动态范围 —— 120dB动态范围



- 信噪比较低
- 空间分辨率较低



研究现状



基于时空最近邻滤波的事件序列去噪重建算法

- 原理简单，实时性高
- 需要人为设定参数，自适应能力差

基于稀疏表示与字典学习的事件序列去噪重建算法

- 自适应能力强
- 运算复杂度高，实时性较差
- 需要二维重构后训练字典，不能实现端到端处理



研究目标：自适应、实时、端到端的高质量事件序列重建方法



目录

CONTENTS

01

研究背景与研究现状

02

研究思路与解决方案

03

实验结果与对比分析


04

总结与展望




事件序列数据集的获取

基于“差分模拟”的事件序列重构数据集生成方法


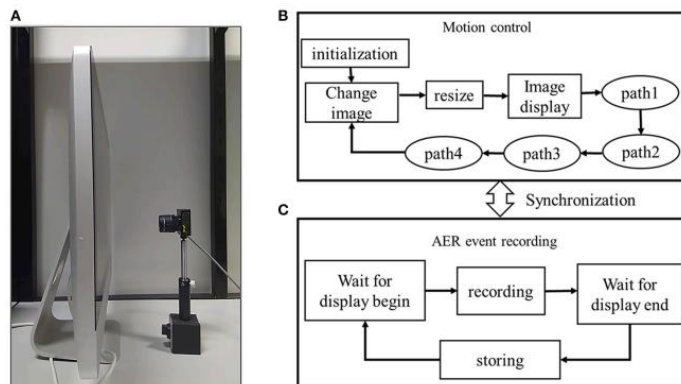


MNIST-DIFF生成原理框图




A: MNIST B: MNIST-DIFF样本 C:MNIST-DIFF 真值

基于“二次采集”的事件序列数据集生成方法



MNIST




N-MNIST




事件序列可视化的实现


基于“视觉暂留”机制的事件序列可视化方法




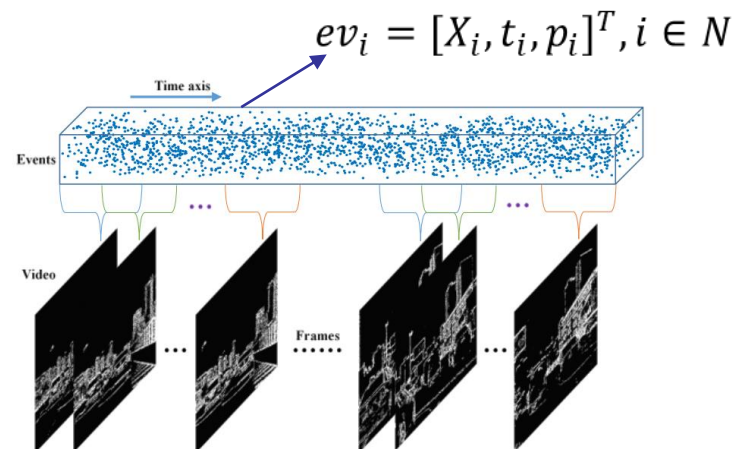
(a)



(b)



(c)




non-overlapped

overlapped




图像重构-卷积去噪自编码器方案ConvDAE

基本原理



DAE



FCN

DAE :去噪自编码器

- ✓ 无监督学习，数据集易获取
- ✓ 保持输入输出结构一致性

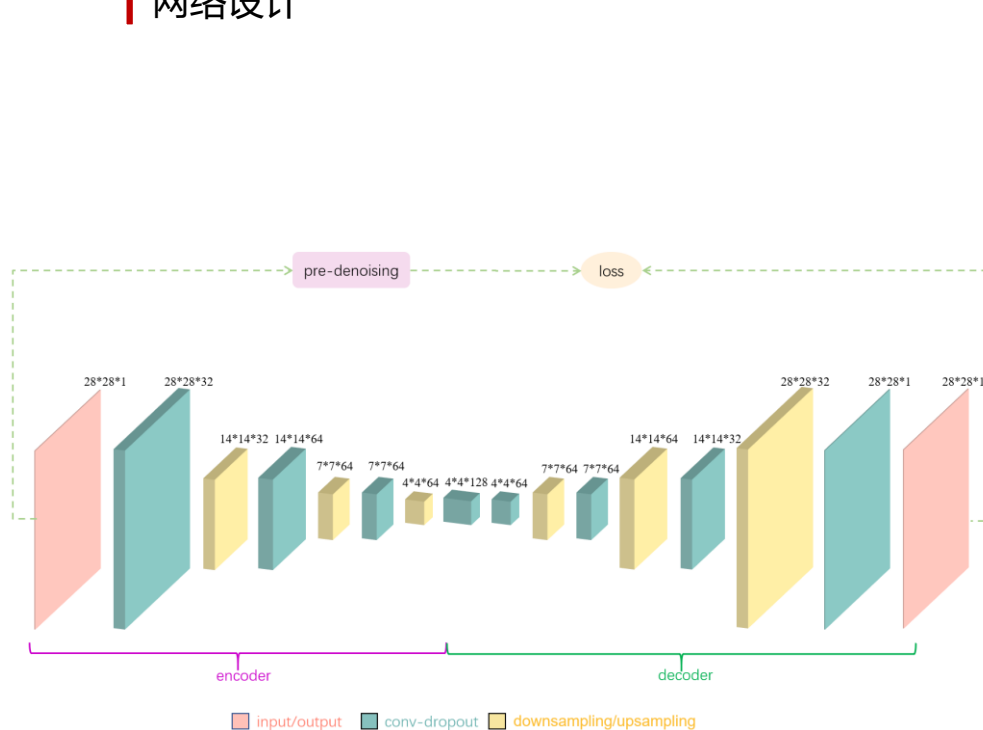
FCN：全卷积网络

- ✓ 局部连接、参数共享，减少网络参数
- ✓ 层次化提取场景不同维度的特征信息



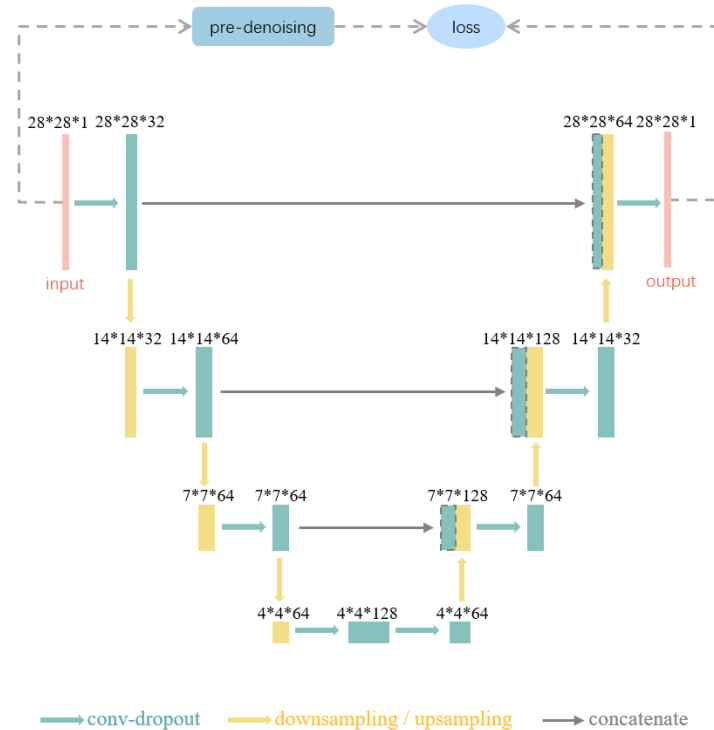
图像重构-卷积去噪自编码器方案ConvDAE

网络设计



L-ConvDAE

“skip connection”




U-ConvDAE



序列切分-循环神经网络方案SeqRNN

基本原理



- ❑ RNN：循环神经网络
- ✓ 与事件序列数据结构相匹配
- ✓ 充分挖掘事件间的时空相关性




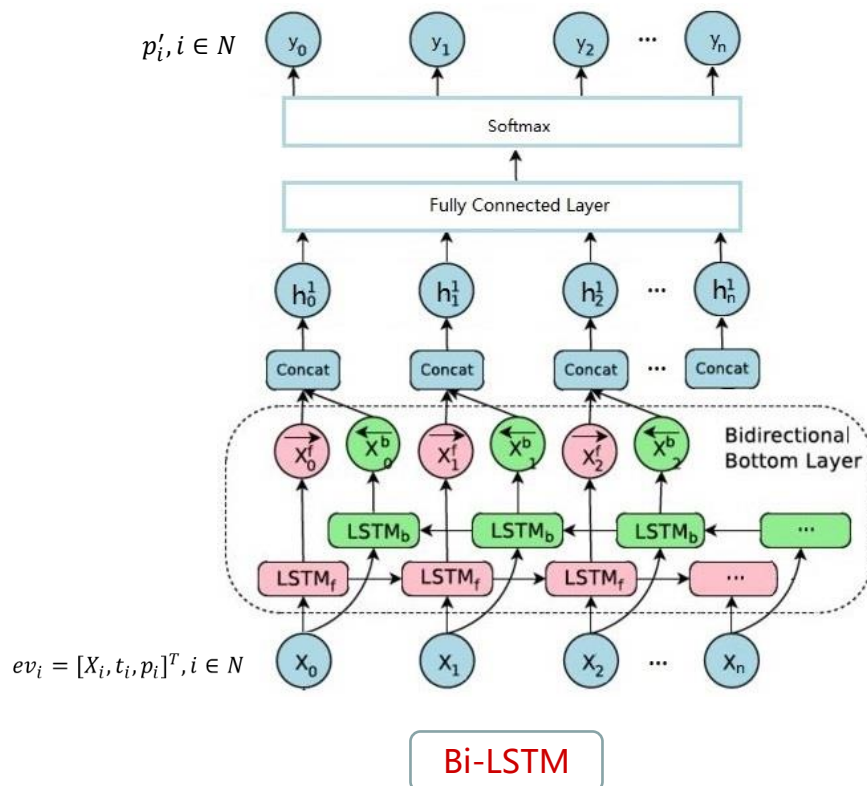
[1] Hochreiter, Sepp, and Jürgen Schmidhuber. "Long short-term memory", Neural computation 9.8 (1997): 1735-1780.

[2] A. Graves, A. Mohamed, and G. Hinton, "Speech recognition with deep recurrent neural networks", ICASSP 2013, Vancouver, BC, Canada, 2013, pp. 6645-6649.



序列切分-循环神经网络方案SeqRNN

网络结构设计





目录

CONTENTS

01

研究背景与研究现状

02

研究思路与解决方案

03

实验结果与对比分析

04

总结与展望



图像重构-卷积去噪自编码器方案ConvDAE

网络训练与测试




表 4.2 网络去噪重建效果测试与对比

网络	数据集	MSE	PSNR	SSIM	time(ms)
MNIST-DIFF	无处理	0.072	17.457	0.599	
	L-ConvDAE	0.050	17.890	0.674	0.143
	U-ConvDAE	0.028	20.554	0.756	0.148
N-MNIST-PIC	无处理	0.052	18.452	0.752	
	L-ConvDAE	0.022	22.664	0.774	0.139
	U-ConvDAE	0.010	26.294	0.950	0.149

损失函数

- ✓ 两种模型收敛较为平滑，训练速度较快
- ✓ U-ConvDAE表现更好、cost更小

评价指标


- ✓ 两种模型各项指标均有改善
- ✓ U-ConvDAE各项指标改善更加明显
- ✓ 可以满足实时性的处理要求



图像重构-卷积去噪自编码器方案ConvDAE

网络预测效果——MNIST-DIFF数据集


L-ConvDAE



input

L-ConvDAE

U-ConvDAE



U-ConvDAE

pre-denoised

方案对比


- ✓ 两种模型均实现了较好的去噪重建效果
- ✓ U-ConvDAE 模型比 L-ConvDAE 模型表现更优



图像重构-卷积去噪自编码器方案ConvDAE

网络预测效果——N-MNIST数据集


L-ConvDAE



input

L-ConvDAE

U-ConvDAE



U-ConvDAE

pre-denoised

方案对比

- ✓ 两种模型均实现了较好的去噪重建效果
- ✓ U-ConvDAE 模型比 L-ConvDAE 模型表现更优



序列切分-循环神经网络方案SeqRNN

网络训练与测试

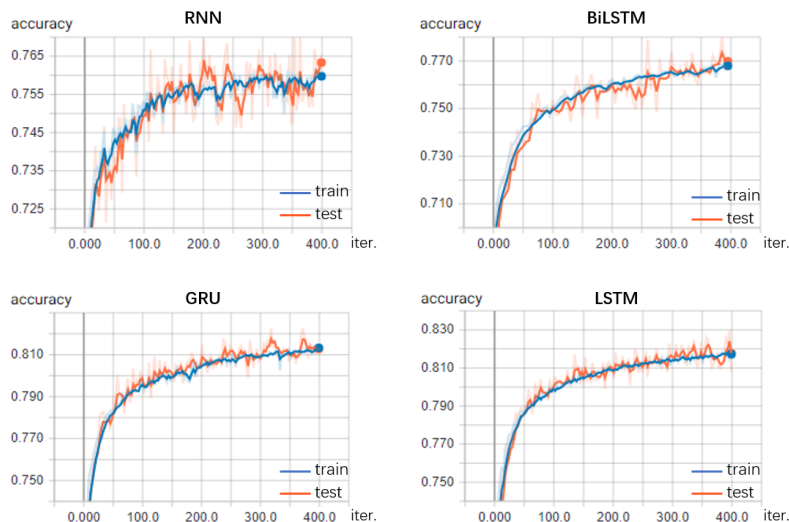


表 5.2 基于 SeqRNN 方案的四种网络模型的预测准确率及平均处理速度（兆事件每秒）

网络	RNN	LSTM	BiLSTM	GRU
测试集准确率	76.3%	81.7%	77.0%	81.4%
处理速度	3.78	2.21	2.63	2.53

训练精度（像素级）

- ✓ RNN震荡较大，LSTM、Bi-LSTM及GRU收敛平缓
- ✓ 收敛速度相对较快


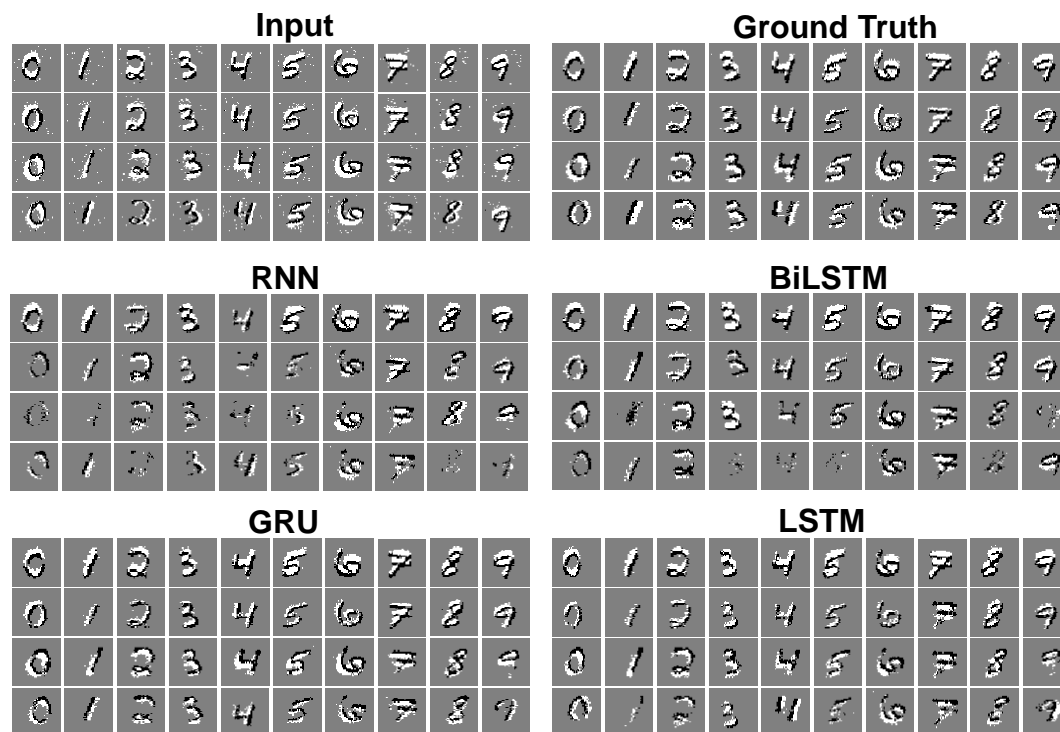
评价指标

- ✓ LSTM和GRU达到了较高的测试精度（>80%）
- ✓ 处理速度均大于2 Meps，满足实时性要求



序列切分-循环神经网络方案SeqRNN

网络预测效果



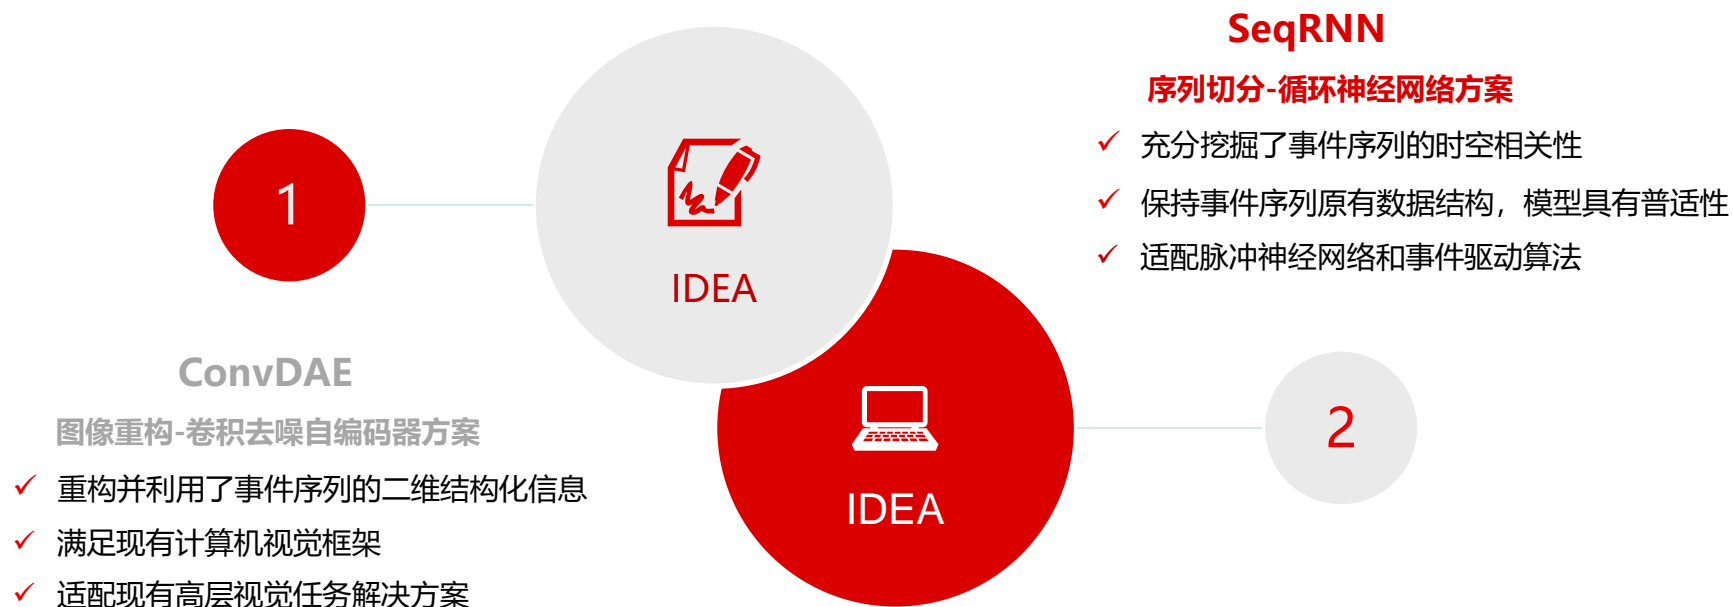
GRU: $x \rightarrow y \rightarrow gt$

- 实现效果
- ✓ 本方案整体上实现了较好的去噪重建效果
- ✓ 部分非噪声稀疏区域存在损失



方案对比

ConvDAE vs. SeqRNN





目录

CONTENTS

01

研究背景与研究现状

02

研究思路与解决方案

03

实验结果与对比分析

04

总结与展望



总结与展望

工作总结

- ✓ 通过“差分模拟”和“二次采集”等方式完成了数据集的获取与预处理
- ✓ 实现了基于“视觉暂留”机制的事件序列可视化方法
- ✓ 提出了图像重构-卷积去噪自编码器方案，并通过两种网络模型进行具体实现，达到了较好的去噪重建效果
- ✓ 提出了序列切分-循环神经网络方案，并在四种循环神经网络模型上进行测试，取得了较好的去噪重建效果

工作展望

- 使用更加完备的事件序列数据集，提升网络的训练效果
- 基于事件序列的二值特性改进网络设计，提升网络性能和速度
- 考虑使用更加贴近生物神经机制的脉冲神经网络完成事件序列重建任务



西安电子科技大学
XIDIAN UNIVERSITY



恳请各位老师批评指正

THANK YOU FOR YOUR ATTENTION

■ 答辩人：张志宏 ■ 指导老师：索津莉 副教授 李洁 教授



补 充 材 料


基于深度网络的高质量事件序列 (Event Sequence) 重建

- 答辩人：
电子工程学院 张志宏
- 指导老师：
清华大学 索津莉 副教授
西安电子科技大学 李洁 教授




事件序列数据集的获取

基于“差分模拟”的事件序列重构数据集生成方法



MNIST-DIFF生成原理框图



A: MNIST B: MNIST-DIFF样本 C: MNIST-DIFF 真值

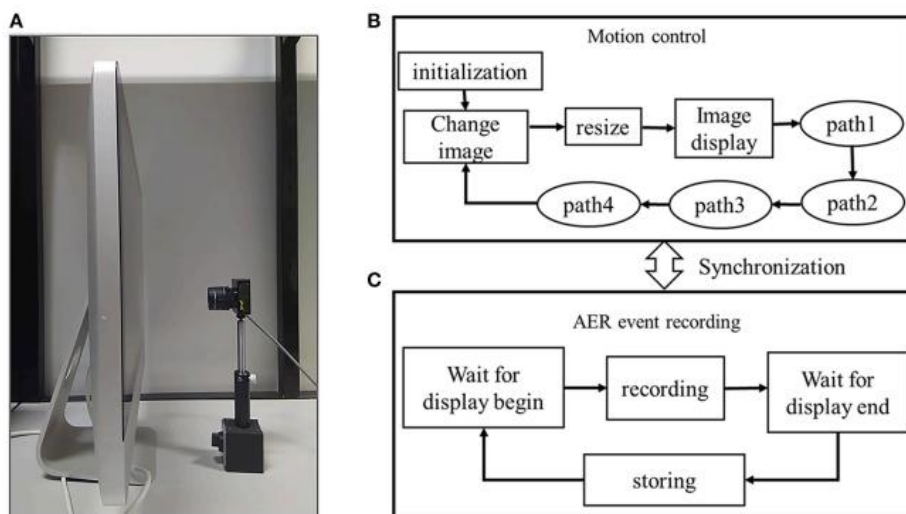
□ MNIST→MNIST-DIFF

- ✓ 利用现有视觉数据集资源，节省人力物力
- ✓ 原理简单，易于获取，为算法可行性提供初步验证



事件序列数据集的获取


基于“二次采集”的事件序列数据集生成方法



二次采集原理框图



MNIST



N-MNIST

N-MNIST数据示例


❑ MNIST→N-MNIST

- ✓ 利用现有视觉数据集资源，节省人力物力
- ✓ 统一测试基准，便于计算机视觉和神经形态视觉算法之间的比较




📷 序列切分-循环神经网络方案SeqRNN


网络预测效果——迁移应用



input



output



- 实现效果
- ✓ 整体上具有一定的噪声滤除效果
- ✓ 通过迁移学习可进一步提升网络去噪重建性能



网络参数与训练测试平台配置

ConvDAE方案

表 4.1 L-ConvDAE 的网络层级及参数配置

layers		patch size	stride	output size
inut				28×28×1
encoder	conv_1	3×3	1	28×28×32
	max pool_1	2×2	2	14×14×32
	conv_2	3×3	1	14×14×64
	max pool_2	2×2	2	7×7×64
	conv_3	3×3	1	7×7×64
	max pool_3	2×2	2	4×4×64
mid-layer	conv_4	3×3	1	4×4×128
decoder	conv_5	3×3	1	4×4×64
	deconv_1	2×2	2	7×7×64
	conv_6	3×3	1	7×7×64
	deconv_2	2×2	2	14×14×64
	conv_7	3×3	1	14×14×32
	deconv_3	2×2	2	28×28×32
output	conv_8	3×3	1	28×28×1

训练平台配置

- ✓ CPU: Core i5-7300HQ CPU, 2.5GHz, 8G
- ✓ GPU: NVIDIA GeForce GTX 1050Ti GPU, 4G

测试平台配置

- ✓ CPU: Core i5-7300HQ CPU, 2.5GHz, 8G
- ✓ GPU: NVIDIA GeForce GTX 1050Ti GPU, 4G



网络配置与训练测试平台配置

SeqRNN方案

表 5.1 SeqRNN 方案的四种具体网络模型实现

layers		input size	output size
inut		64×4	64×4
bottom (4 选 1)	RNN_1	64×4	64×64
	RNN_2	64×64	64×32
	LSTM_1	64×4	64×64
	LSTM_2	64×64	64×32
	GRU_1	64×4	64×64
	GRU_2	64×64	64×32
	BiLSTM_f	64×4	64×32
	BiLSTM_b	64×4	64×32
fully connected		64×32	64×3
output		64×3	64×1

训练平台配置

- ✓ CPU: Core i7-7700K CPU, 4.2GHz, 32G
- ✓ GPU: NVIDIA GeForce GTX 1080Ti GPU, 11G

测试平台配置

- ✓ CPU: Core i5-7300HQ CPU, 2.5GHz, 8G
- ✓ GPU: NVIDIA GeForce GTX 1050Ti GPU, 4G